Qwen3-32B 四卡吞吐对比报告

- 生成时间: 2026-04-03 00:44:19
- 当前服务: `http://127.0.0.1:62274/v1/completions`
- 当前部署环境: `/home/lyq/anaconda3/envs/vllm`
- 当前部署卡数: `4 GPU`
- 历史基线: 仓库内 `2 GPU` 测试结果

当前四卡测试口径

- `2024` 上下文: 输入约 `2025` token，输出 `1024` token，并发 `5 10 20 40 80 160 240`。
- `10000` 上下文: 输入约 `10001` token，输出 `1024` token，并发 `5 10 20 40 80 160 240`。
- 客户端 timeout: `180s`。

部署方法

历史 2 卡基线

- 历史基线直接使用仓库内已有 results_fine 与 results_ctx10k 数据；两组数据均标注为 2 GPU。
- 历史基线接口记录为 http://127.0.0.1:62272/v1/completions，模型路径同样是 /data1/dlx/projects/vllm_xty/model。

当前 4 卡部署

- Conda 环境: /home/lyq/anaconda3/envs/vllm。
- 模型路径: /data1/dlx/projects/vllm_xty/model；服务端口: 62274；GPU: 0,1,2,3。
- 启动前必须设置 CUDA_VISIBLE_DEVICES=0,1,2,3、NCCL_P2P_DISABLE=1、NCCL_CUMEM_ENABLE=0，否则 4 卡实例会卡在初始化阶段。
- 可复现启动脚本: /home/lyq/xintuoyin-KLCLAB/deploy_qwen3_32b_vllm_4gpu.sh。
- 启动命令: vllm serve /data1/dlx/projects/vllm_xty/model --host 0.0.0.0 --port 62274 --served-model-name Qwen3-32B --dtype bfloat16 --tensor-parallel-size 4 --generation-config vllm --gpu-memory-utilization 0.9 --max-model-len 12000 --max-num-seqs 128 --disable-custom-all-reduce --enforce-eager。

当前四卡结论

- `2024` 上下文最高成功吞吐出现在并发 `40`，约 `0.31` req/s，`934.74` tok/s。
- `10000` 上下文最高成功吞吐出现在并发 `40`，约 `0.23` req/s，`2514.76` tok/s。
- `2024` 上下文首个出现 timeout 的并发点是 `80`，timeout 比例 `100.00%`。
- `10000` 上下文首个出现 timeout 的并发点是 `80`，timeout 比例 `100.00%`。

当前四卡 2024 vs 10000

并发	2024 成功	2024 Timeout%	2024 req/s	2024 tok/s	10000 成功	10000 Timeout%	10000 req/s	10000 tok/s
5	10	0.00%	0.06	197.61	10	0.00%	0.06	653.98
10	10	0.00%	0.08	231.93	10	0.00%	0.06	715.77
20	20	0.00%	0.17	508.47	20	0.00%	0.16	1719.39
40	40	0.00%	0.31	934.74	40	0.00%	0.23	2514.76
80	0	100.00%	0.00	0.00	0	100.00%	0.00	0.00
160	0	100.00%	0.00	0.00	0	100.00%	0.00	0.00
240	0	100.00%	0.00	0.00	0	100.00%	0.00	0.00

历史 2 卡 vs 当前 4 卡: 2024 上下文

并发	2卡 req/s	4卡 req/s	req/s 变化	2卡 tok/s	4卡 tok/s	tok/s 变化	2卡 Timeout%	4卡 Timeout%
5	0.09	0.06	-27.70%	275.46	197.61	-28.26%	0.00%	0.00%
10	0.16	0.08	-53.24%	499.92	231.93	-53.61%	0.00%	0.00%
20	0.28	0.17	-40.90%	867.14	508.47	-41.36%	0.00%	0.00%
40	0.46	0.31	-33.75%	1422.06	934.74	-34.27%	0.00%	0.00%
80	0.65	0.00	-100.00%	1995.00	0.00	-100.00%	0.00%	100.00%
160	0.45	0.00	-100.00%	1370.26	0.00	-100.00%	48.75%	100.00%

历史 2 卡 vs 当前 4 卡: 10000 上下文

并发	2卡 req/s	4卡 req/s	req/s 变化	2卡 tok/s	4卡 tok/s	tok/s 变化	2卡 Timeout%	4卡 Timeout%
5	0.08	0.06	-23.51%	855.01	653.98	-23.51%	0.00%	0.00%
10	0.14	0.06	-53.36%	1534.78	715.77	-53.36%	0.00%	0.00%
20	0.23	0.16	-31.57%	2512.57	1719.39	-31.57%	0.00%	0.00%
40	0.34	0.23	-32.54%	3727.55	2514.76	-32.54%	0.00%	0.00%
80	0.00	0.00	N/A	0.00	0.00	N/A	100.00%	100.00%
160	0.00	0.00	N/A	0.00	0.00	N/A	100.00%	100.00%

原始产物

- 当前 2024 汇总: `results_4gpu_ctx2024/summary.csv`
- 当前 10000 汇总: `results_4gpu_ctx10k/summary.csv`
- 当前 2024 图表: `results_4gpu_ctx2024/benchmark.svg`
- 当前 10000 图表: `results_4gpu_ctx10k/benchmark.svg`
- 历史对比表: `historical_comparison.csv`